Sécurité de l'IA Générative

Étude de la mémorisation dans les modèles génératifs

Liens avec le surapprentissage et implications pour la confidentialité des données, un angle sécurité

Présenté par : Emmanuel SININI et Fatima-Zahra Rhoulam

Encadrants : Maryline Laurent (TSP) · Faiz Taleb (TSP / EDF)

Télécom SudParis

1ère réunion de projet

Plan

1. Contexte : L'IA Générative

2. Attaques sur les systèmes d'IA

3. Mémorisation et surapprentissage

4. Objectifs et plan de travail

5. Questions pour la réunion

Contexte

L'IA générative crée du contenu réaliste

Deux familles dominent : les GAN (Goodfellow) et les modèles à mécanisme d'attention (Vaswani) à la base de ChatGPT, DALL-E, etc.

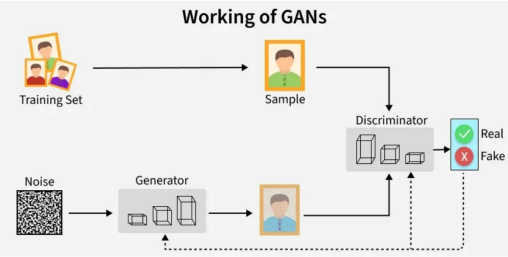
Ces modèles génèrent des contenus de **même nature** que leurs données d'entraînement : le risque de mémorisation devient direct et exploitable.

Le risque identifié

La mémorisation permet des **attaques d'inversion de modèle** : extraction de données sensibles, de paramètres ou d'architecture.

Déjà démontré : extraction sur LLM (Carlini 2021), fuite de PII (Lukas), détection d'appartenance sur GAN de visages (Webster 2023).

Les GAN - Generative Adversarial Networks



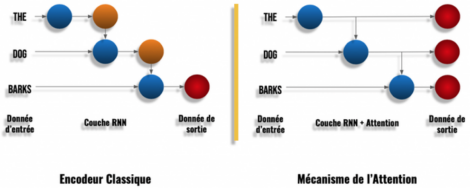
https://www.geeksforgeeks.org/machine-learning/basics-of-generative-adversarial-networks-gans/

Challenges :

- Mode collapse : G se met à produire toujours le même type de sortie (peu de diversité), parce que c'est suffisant pour tromper D.
- Mémorisation : au lieu d'apprendre la distribution générale des visages (par exemple), G peut apprendre à reproduire quasiment à l'identique certains visages précis du jeu d'entraînement surtout ceux qui sont rares ou atypiques (lien direct avec Feldman et la longue traîne).

Les modèles à mécanisme d'attention (1/3)

- **Le problème résolu :** avant 2017, réseaux récurrents (RNN, LSTM) qui lisent mot par mot, dans l'ordre → lents, « oublient » les débuts de phrase longue
- **L'idée centrale, l'attention :** le modèle regarde toute la séquence à la fois ; pour chaque mot, il calcule à quel point « faire attention » à chacun des autres pour construire sa représentation
- **Trois vecteurs par token** (mot ou fragment de mot) :
  - Query (Q) « qu'est-ce que je cherche ? »
  - Key (K) « qu'est-ce que je peux offrir ? »
  - Value (V) « quelle information je transmets si on



https://www.linkedin.com/pulse/
ia-les-modèles-dattention-jean-baptiste-executive-mba-mpa-msc-ma-che

Le Transformer

- Architecture complète construite autour de ce mécanisme
- **Multi-head attention :** plusieurs attentions en parallèle («têtes»), chacune capte un type de relation différent (syntaxique, sémantique…)
- **Feed-forward layers,** empilées en plusieurs couches
- **Positional encoding :** l'attention regarde tout en même temps (sans ordre inhérent) → on injecte la position des mots dans la séquence

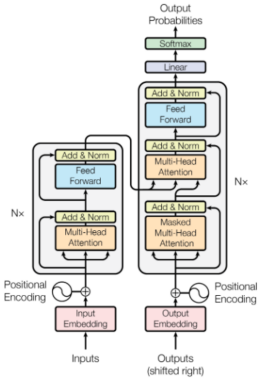


Figure 1: The Transformer - model architecture.

https://arxiv.org/abs/1706.03762

Attention et mémorisation

- Regarder toute la séquence à la fois $\rightarrow$ très efficace pour retenir des motifs précis, y compris des séquences entières rencontrées à l'entraînement
- Attaques d'extraction (Carlini 2021) : on donne un préfixe, le modèle continue ; il utilise l'attention pour « retrouver » la suite exacte s'il l'a mémorisée
- Perplexité anormalement basse (signe de mémorisation) : le modèle est extrêmement confiant sur la suite d'une séquence déjà vue, car l'attention l'a apprise à reconnaître presque comme un identifiant

Les modèles de diffusion : Stable Diffusion, DALL-E (1/2)

L'idée centrale : apprendre à débruiter progressivement une image, puis utiliser ce savoir-faire à l'envers pour générer une image à partir de bruit pur.

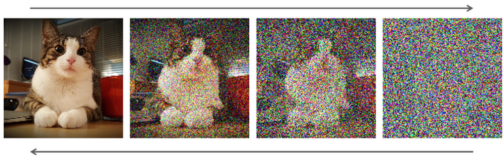
– Le processus d'entraînement (forward process) :

- On part d'une vraie image du jeu d'entraînement.
- On lui ajoute du bruit gaussien, petit à petit, sur des centaines d'étapes (T étapes), jusqu'à obtenir du bruit pur (image totalement illisible).
- À chaque étape, le modèle est entraîné à prédire quel bruit a été ajouté autrement dit, à faire le chemin inverse : « si je vois cette image légèrement bruitée, quelle était l'image un peu moins bruitée juste avant ? »

Les modèles de diffusion : Stable Diffusion, DALL-E (2/2)

– La génération (reverse process) :

- On part d'un bruit aléatoire pur.
- On applique le modèle T fois de suite, chaque passage retirant un peu de bruit.
- Au bout du processus, on obtient une image « neuve », qui suit la même distribution statistique que les images d'entraînement.



https://www.linkedin.com/pulse/
ia-les-modèles-dattention-jean-baptiste-executive-mba-mpa-msc-ma-ch

Plan

1. Contexte : L'IA Générative

2. Attaques sur les systèmes d'IA

3. Mémorisation et surapprentissage

4. Objectifs et plan de travail

5. Questions pour la réunion

Les attaques sur un système IA

Phase	Manipulation	Infection	Exfiltration
Phase d'apprentissage		Attaques par empoisonnement (poisoning attacks) ; Attaques par porte dérobée (backdooring attacks)	Attaques par inférence d'appartenance (membership inference attacks)
Phase de production	Attaques par évasion (evasion attacks) ; Attaques par reprogrammation (reprogramming attacks) ; Attaques par déni de service		Attaques par inversion (model inversion attacks) ; Attaques d'extraction de modèle (model extraction attacks)

Familles d'attaques

Famille	Prérequis	Principe	Mitigation
Membership Inference	Boîte noire ; données shadow similaires	Confiance / loss plus faible sur le train ; classifieur d'attaque	DP-SGD, régularisation, masquer les logits
Extraction de données	Accès génératif ; génération massive ou préfixe connu	Génère en masse, repère la basse perplexité, vérifie la source	Déduplication, DP, filtrage des sorties
Model Inversion	Boîte noire / grise ; structure des données connue	Optimiser une entrée pour maximiser une classe cible	Limiter les scores renvoyés, DP
Attribute Inference	Accès aux sorties ; connaissance partielle de l'individu	Corréler des attributs visibles avec des attributs cachés	Réduire les corrélations sensibles, audits
Gradient Inversion	Boîte blanche sur les gradients (apprentissage fédéré)	Optimiser une donnée dont les gradients imitent ceux observés	Agrégation sécurisée, DP sur les gradients

Comment on exploite un modèle

Classifier les attaques par cible

SUR L'INFÉRENCE

Modèle figé, on l'interroge

- Membership Inference (MIA)
- Extraction de données d'entraînement
- Attribute / Property Inference
- Model Inversion

→ terrain principal de ce sujet, orienté IA générative

SUR L'ENTRAÎNEMENT

L'attaquant agit pendant l'apprentissage

- Data poisoning
- Gradient inversion (apprentissage fédéré)
- Analyse de checkpoints intermédiaires

→ utile pour l'objectif 1 : quand la mémorisation apparaît-elle ?

Question centrale

Prédictif vs génératif : quelle différence ?

Critère	Modèle prédictif (classifieur)	Modèle génératif (LLM, diffusion, GAN)
Sortie	Une étiquette / probabilité par classe	Un contenu nouveau (texte, image)
Signal exploité	Confiance de classification	Perplexité, reconstruction exacte
Attaque typique	MIA classique (Shokri, 2017)	Extraction verbatim (Carlini)
Donnée reconstruite	Rarement l'exemple entier	Souvent l'exemple complet, verbatim
Gravité	Fuite d'appartenance seule	Appartenance + contenu lui-même

Sur un modèle génératif, l'attaque ne devine pas un booléen — elle peut faire sortir le texte ou l'image d'origine, mot pour mot ou pixel pour pixel.

Une attaque d'extraction sur un LLM (1/2)

- **Étape 1 : Générer massivement :**
  L'attaquant envoie au modèle un grand nombre de prompts, souvent de simples débuts de phrase variés et laisse le modèle continuer sa génération. On collecte des centaines de milliers de sorties.
- **Étape 2 : Favoriser la diversité (sampling)**
  Pour ne pas obtenir toujours les mêmes réponses génériques, on joue sur les paramètres de décodage (température , variation du top-k / top-p)
- **Étape 3 : Repérer les candidats suspects (le filtrage)**
  Parmi toutes ces sorties générées, l'attaquant cherche celles qui ont un comportement statistique anormal, signe possible de mémorisation :
  - Perplexité anormalement basse [le modèle est beaucoup plus confiant sur cette séquence que sur du texte générique].
  - Comparaison à des modèles de référence par exple zlib , GPT-2 plus petit...

Une attaque d'extraction sur un LLM (2/2)

- **Étape 4 : Vérification**
  Une fois qu'on a une liste de candidats suspects (par exemple les 1000 textes avec le ratio le plus bas), on vérifie s'ils correspondent réellement à des données existantes.
- **Étape 5 : Mesurer l'ampleur du phénomène**

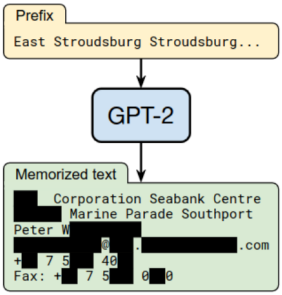
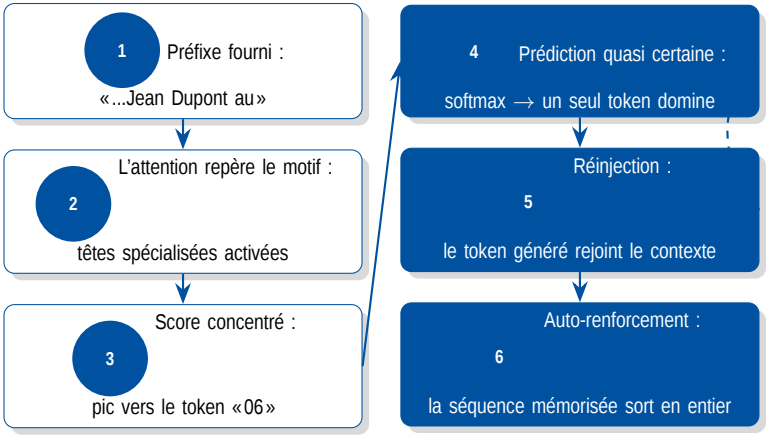


Figure 1: **Our extraction attack.** Given query access to a neural network language model, we extract an individual person's name, email address, phone number, fax number, and physical address. The example in this figure shows information that is all accurate so we redact it to protect privacy.

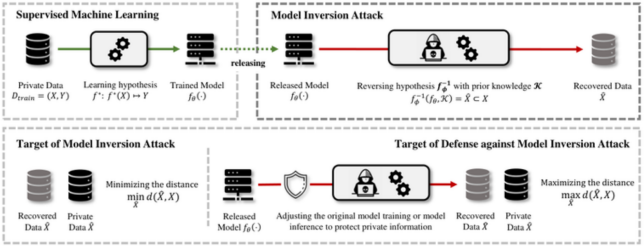
https://www.usenix.org/system/files/sec21-carlini-extracting.pdf

Comment l'attention est exploitée dans une extraction



Une attaque de Model Inversion (1/2)

– Un modèle de classification apprend une fonction f qui va d'une entrée x (une image, par exemple) vers une sortie y (une probabilité par classe, comme "Personne A","Personne B"…). L'inversion de modèle retourne le problème :
Au lieu de demander « à qui appartient ce visage ? », l'attaquant demande « à quoi ressemble le visage de la Personne A, selon ce que le modèle a appris ? »



Une attaque de Model Inversion (2/2)



Figure 10. Image de visage extrait à l'aide d'une attaque par inversion de modèle (à gauche) et image d'entraînement correspondante (à droite)
*(**Fredrikson et al.**, 2015)*

Plan

1. Contexte : L'IA Générative

2. Attaques sur les systèmes d'IA

3. Mémorisation et surapprentissage

4. Objectifs et plan de travail

5. Questions pour la réunion

Objectifs du projet

Trois objectifs, un fil conducteur

01 Comprendre la mémorisation

Comment et pourquoi les modèles mémorisent. À quelle étape (début / milieu / fin) et quels facteurs favorisent l'émergence.

02 Relier mémorisation et surapprentissage

Dans quelles conditions ces deux phénomènes coïncident, ou au contraire se distinguent clairement.

03 Détecter et évaluer le risque

Comparer des métriques de détection et les relier au risque réel de divulgation d'informations sensibles — **mon angle sécurité**.

Définitions (1/2)

Trois notions à ne pas confondre

Généralisation

Le modèle performe bien sur des données jamais vues pendant l'entraînement.
Mesure : écart entre erreur de train et de test.

Surapprentissage

Bon sur les données d'entraînement, mauvais sur des données nouvelles.
Symptôme : grand écart train / test. Problème global de performance.

Définitions (2/2)

Trois notions à ne pas confondre

Mémorisation

Le modèle reproduit (presque) exactement un exemple d'entraînement précis.
Feldman (2020) : différence de prédiction correcte avec / sans l'exemple dans le train. Phénomène **local**, pas global.

Point clé du sujet : mémorisation $\neq$ surapprentissage

Distinction clé

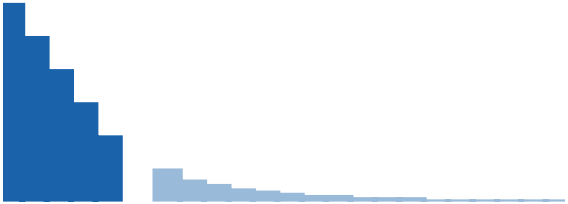
Mémorisation ≠ surapprentissage

Aspect	Surapprentissage	Mémorisation
Niveau	Global — tout le modèle	Local — des exemples précis
Symptôme	Écart train / test élevé	Un exemple restitué ou très influent
Effet sur la performance	Dégrade le test	Neutre, parfois utile
Détection	Courbes train / test	Attaques, tests contrefactuels

Un modèle peut très bien généraliser et pourtant mémoriser certains exemples : les défenses classiques contre l'overfitting ne suffisent donc pas à protéger la confidentialité.

Pourquoi la mémorisation existe (1/2)

L'argument de la longue traîne (Feldman, 2020)



Tête (à gauche) :
motifs fréquents, appris par une règle générale.

Longue traîne (à droite) :
une énorme quantité de cas rares, sans règle générale possible.

Pourquoi la mémorisation existe (2/2)

Pour bien traiter ces cas rares au moment du test, le modèle doit **retenir les exemples eux-mêmes** — donc mémoriser améliore la généralisation.

Conséquence sécurité : les exemples rares et atypiques — souvent des données personnelles — sont justement ceux que le modèle a intérêt à mémoriser.

Facteurs déterminants

Quand les attaques sont-elles efficaces ?

Liés au modèle

Taille du modèle, sur-paramétrisation, écart train / test élevé

Liés aux données

Duplication (effet non linéaire), rareté / atypicité, longueur de la séquence

Liés à l'entraînement

Nombre d'époques, étape d'entraînement, absence de régularisation / DP

Liés à l'attaque

Qualité du préfixe / prompt, budget de requêtes, accès aux logits (boîte grise)

Plan

1. Contexte : L'IA Générative

2. Attaques sur les systèmes d'IA

3. Mémorisation et surapprentissage

4. Objectifs et plan de travail

5. Questions pour la réunion

Choix à trancher en réunion (1/2)

Sur quelle étape se concentrer ?

Prédiction / génération — modèles pré-entraînés

Cœur du sujet : extraction et MIA en boîte noire/grise sur GPT-2, Pythia, petits modèles de diffusion — pas besoin de ré-entraîner

Entraînement — via les checkpoints Pythia

Répond à l'objectif 1 (quand la mémorisation apparaît) sans le coût d'un entraînement complet

Choix à trancher en réunion (2/2)

Sur quelle étape se concentrer ?

Classification — repère théorique seulement

Utile en slide pédagogique (MIA historique), mais hors périmètre expérimental — s'éloigne de l'IA générative

Question ouverte : quel budget de calcul est disponible ?

Mon angle (1/2)

Un modèle de menace explicite

- **Qui est l'attaquant ?**
  Utilisateur curieux, concurrent, insider
- **Quel accès ?**
  Boîte blanche, grise ou noire
- **Que sait-il ?**
  Distribution, architecture, shadow models, préfixe connu
- **Que veut-il ?**
  Extraction, MIA, inférence d'attributs, reconstruction

Mon angle (2/2)

Un modèle de menace explicite

Risque = probabilité de succès de l'attaque × sensibilité de la donnée × faisabilité pour l'attaquant. **Objectif : relier métriques de mémorisation et risque réel de fuite.**

Plan de travail proposé

Chaque sprint alimente le rapport

Sprint 1

État de l'art
Snowballing depuis Carlini et Feldman ; bases (MIA, overfitting) pour les slides

Sprint 2

Protocole et modèle de menace
Choix des modèles à tester, définition précise du scénario d'attaque

Sprint 3

Attaques en génération
MIA et extraction sur modèles pré-entraînés ; premières métriques

Sprint 4+

Mémorisation au fil de l'entraînement
Checkpoints Pythia ; lien métriques $\leftrightarrow$ risque réel

Plan

1. Contexte : L'IA Générative

2. Attaques sur les systèmes d'IA

3. Mémorisation et surapprentissage

4. Objectifs et plan de travail

5. Questions pour la réunion

Pour la réunion

- Quel type de modèle privilégier (LLM, diffusion, GAN) vu les ressources de calcul disponibles ?
- Faut-il entraîner nos propres petits modèles, ou attaquer des modèles pré-entraînés ?
- Y a-t-il un cas d'usage EDF particulier (données sensibles, contexte industriel) ?
- Quels livrables et quel calendrier sont attendus ?
- Une partie défense (DP, déduplication) est-elle attendue, ou seulement l'analyse et la détection ?