Sécurité de l'IA Générative

Étude de la mémorisation et implications pour la confidentialité

Équipe Projet

Télécom SudParis

3 octobre 2026

Plan de la présentation

1 Le paysage des modèles IA

2 La mécanique des attaques

3 Le cœur théorique

4 Gestion du Projet

Contexte : L'IA Générative

- **Objectif :** Créer du contenu réaliste (texte, images).
- **Deux familles dominantes :**
  - Les **GAN** (Generative Adversarial Networks) de Ian Goodfellow.
  - Les modèles à **mécanisme d'attention** (Transformers) de Vaswani et al.
- **Le risque identifié :**

Mémorisation et Confidentialité

Ces modèles génèrent des contenus similaires à leurs données d'entraînement. Le risque d'extraction de données sensibles (PII) est critique.

L'architecture Transformer et l'Attention

- **Le mécanisme d'attention :**
  - Le modèle regarde toute la séquence simultanément.
  - Utilisation des vecteurs *Query*, *Key*, et *Value*.
- **Implication Sécurité :**
  - La capacité à capter l'ensemble du contexte favorise la **mémorisation verbatim**.
  - Lors d'une attaque, face à un préfixe, le modèle restitue la suite mémorisée avec une *perplexité anormalement basse*.

Prédictif vs Génératif

Aspect	Modèle Prédictif	Modèle Génératif
Sortie	Probabilité / Étiquette	Contenu nouveau
Signal exploité	Confiance de classification	Perplexité, reconstruction
Attaque typique	MIA (Membership Inference)	Extraction verbatim (Carlini)
Gravité	Fuite d'appartenance	Appartenance + Contenu

Attaque d'extraction sur un LLM (5 étapes)

Basée sur les travaux de **Carlini et al. (2021)** :

1. **Générer massivement :** Utiliser des préfixes variés.
2. **Diversité (Sampling) :** Ajuster la température, le top-k, le top-p.
3. **Filtrage :** Repérer les séquences avec une perplexité anormalement basse (comparaison avec un modèle de référence type zlib).
4. **Vérification :** Isoler les meilleurs candidats et vérifier leur présence dans les données d'entraînement.
5. **Mesure :** Quantifier le phénomène d'extraction.

Définitions Clés

Surapprentissage (Overfitting)

Le modèle excelle sur les données d'entraînement mais échoue sur de nouvelles données. C'est un problème **global**.

Mémorisation

Le modèle reproduit exactement un exemple précis. C'est un phénomène **local**.

Distinction cruciale : Un modèle peut très bien généraliser sans surapprendre, tout en mémorisant. Les défenses classiques (DropOut) ne protègent pas la confidentialité !

La longue traîne (Feldman, 2020)

- **Tête de distribution :** Motifs fréquents et règles générales.
- **Longue traîne :** Cas rares, atypiques, impossibles à généraliser.

Conséquence de sécurité

Pour être performant sur ces données atypiques, le modèle est obligé de les **mémoriser par cœur**. Ces données (souvent des informations personnelles) sont donc les plus vulnérables à l'extraction.

Modèle de Menace & Objectif Sécurité

- **Adversaire :** Utilisateur curieux, concurrent, insider.
- **Accès :** Boîte noire, grise ou blanche.
- **Objectif final :** Ne pas se limiter à une métrique technique, mais évaluer le risque de fuite concret.

$$Risque = P(Succs) \times Sensibilit \times Faisabilit$$

Plan d'Action - Approche Agile

Sprint 1 : État de l'art (MIA, Overfitting, Extraction).

Sprint 2 : Protocole et Modèle de menace, choix des modèles.

Sprint 3 : Attaques en génération (MIA, Extraction sur modèles pré-entraînés).

Sprint 4 : Évolution de la mémorisation et corrélation avec le risque réel.