Sécurité de l'IA Générative

Étude de la mémorisation dans les modèles génératifs

Liens avec le surapprentissage et implications pour la confidentialité des données, un angle sécurité

Présenté par : Emmanuel SININI et Fatima-Zahra Rhoulam

Encadrants : Maryline Laurent (TSP) · Faiz Taleb (TSP / EDF)

Télécom SudParis

1ère réunion de projet

Plan

1. Classification d'Images (CNN CIFAR-10)

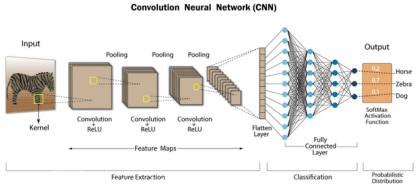
2. Séries Temporelles (LSTM)

3. Génération Textuelle (NanoGPT)

4. Modèles de Diffusion (DDPM)

5. Synthèse Croisée Globale

CNN — Architecture & Forward Pass



Architecture générale d'un CNN : extraction de caractéristiques & classification

Source : N. Shahriar, *"What is Convolutional Neural Network (CNN) in Deep Learning?"* · LinkedIn

- **Convolution :** Filtres détectant les motifs locaux hiérarchiques (contours, textures).
- **Pooling :** Réduction spatiale assurant la robustesse aux translations.
- **Softmax :** $\text{Softmax}(z_i) = \frac{\exp(z_i)}{\sum_j \exp(z_j)} \Longrightarrow$ distribution prédictive sur les classes.

CNN — La Fonction de Perte comme Origine du Signal

Cross-Entropy Loss (Entropie Croisée)

$$\mathcal{L}_{\text{CE}} = -\log\left(p_{\text{classe correcte}}\right)$$

- Minimisation stricte sur les exemples d'entraînement.
- **Image Train :** $p_{\text{max}} \to 1 \implies \mathcal{L}_{\text{CE}} \approx 0.$
- **Image Test (inédite) :** p_{max} modéré $\implies \mathcal{L}_{\text{CE}}$ nettement plus élevée.

Conséquence Opérationnelle (Surapprentissage)

L'**écart de confiance** entre train et test constitue la définition opérationnelle du surapprentissage.

- Le réseau est « sur-confiant » sur les données vues.
- Cet écart résiduel est le **signal fondamental** exploité par les attaques d'inférence (MIA).

Réf : Shokri et al. (IEEE S&P 2017) · Yeom et al. (IEEE CSF 2018)

CNN — Attaque Déduite : Membership Inference (MIA)



- **Shokri et al. (IEEE S&P 2017) :** Entraînement de multiples *shadow models* mimant le comportement du modèle cible, puis apprentissage d'un classifieur d'attaque supervisé.
- **Yeom et al. (IEEE CSF 2018) :** Seuil analytique direct sur la perte : $\mathcal{M}(x) = \mathbb{I}(\mathcal{L}(x) \leq \tau)$.
- **Lien théorique :** L'avantage de l'attaquant est directement borné par l'écart de généralisation : $\text{Adv} \leq \text{Acc}_{\text{train}} - \text{Acc}_{\text{test}}$.

Shadow Models & Classifieur d'Attaque (Shokri et al.)

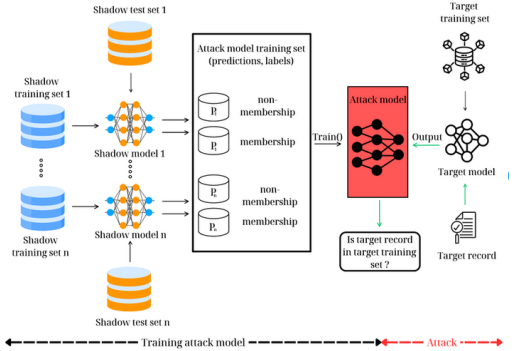


Fig. : Workflow des attaques par inférence d'appartenance (MIA) via *Shadow Models*.

Source : C. C. Nikolaidis, *"A study of membership inference attacks on a federated health care application"*, Computing 107(7), 2025. DOI: 10.1007/s00607-025-01507-x

CNN — Analyse Empirique : Exemple Chiffré sur CIFAR-10

Métrique observée	Image Train (IN)	Image Test (OUT)
Confiance $p_{\max}$ (« chat »)	**0,994**	0,710
Perte $\mathcal{L}_{\text{CE}} = -\log(p_{\max})$	**0,006**	0,342
Ratio de perte (Test / Train)	**Facteur 57$\times$ d'écart**	
Verdict ($\tau = 0{,}05$)	**IN (Correct)**	**OUT (Correct)**

Constat d'Exploitation

- Avec un seuil calibré $\tau = 0{,}05$, l'attaquant sépare parfaitement les deux images.
- **Origine physique :** L'optimisation force la convergence des poids vers les détails stochastiques d'entraînement (bruit haute fréquence propre au train set).

Plan

1. Classification d'Images (CNN CIFAR-10)

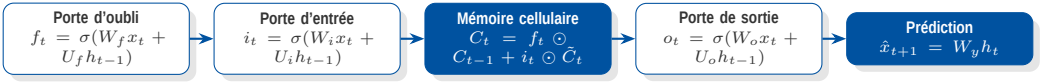
2. Séries Temporelles (LSTM)

3. Génération Textuelle (NanoGPT)

4. Modèles de Diffusion (DDPM)

5. Synthèse Croisée Globale

LSTM — Architecture & Forward Pass



$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

- **Porte d'oubli f_t :** Proportion d'information conservée de l'état passé C_{t-1}.
- **Porte d'entrée i_t :** Degré de mise à jour par la nouvelle entrée $\tilde{C}_t$.
- **Porte de sortie o_t :** Exposition sélective de la mémoire cellulaire vers $h_t \to \hat{x}_{t+1}$.

LSTM — L'Erreur de Prédiction MSE comme Signal

Erreur Quadratique Moyenne (MSE)

$$\mathcal{L}_{\text{MSE}} = \left(\hat{x}_{t+1} - x_{t+1}\right)^2$$

- Optimisation par rétropropagation à travers le temps (BPTT).
- **Séquence Train :** Erreur résiduelle anormalement basse ($< 10^{-3}$).
- **Séquence Test :** Erreur de prédiction nettement plus élevée en moyenne.

Analogie avec la Perplexité des LLM

Pour une série temporelle continue, l'erreur MSE joue le rôle exact de la **perplexité** :

- Elle quantifie la **surprise** locale du réseau face à la dynamique observée.
- Un résidu proche de zéro trahit une mémorisation mécanique de la série temporelle.

LSTM — Attaque Déduite : Canaris & Métrique d'Exposure



- **Protocole *The Secret Sharer* (Carlini et al., USENIX 2019) :** Insertion d'un motif temporel rare et génération de variantes fictives candidates.
- **Formule de l'Exposure :** $\text{Exposure}(s) = \log_2 |Q| - \log_2 \text{Rang}(s)$.
- **Interprétation :** Un rang de 1 signifie que le canari est dissociable de tout le bruit de fond, prouvant une mémorisation absolue dans les poids du modèle.

LSTM — Exemple Chiffré & Évolution par Époque

Mesure Expérimentale	Valeur Observée
MSE sur le canari secret exact	0,0004
MSE moyenne sur les séquences de test	0,1830
Ratio de résidu (Test / Canari)	Facteur 450×
Rang du canari parmi 10 variantes	1er / 10

Dynamique Temporelle d'Apparition

- **À 20 époques :** Le canari est confondu avec le bruit (Rang $\approx 6/10$).
- **À 100 époques :** Décrochage net de la MSE (Rang $\rightarrow 2/10$).
- **À 200 époques :** Mémorisation stricte (Rang $= 1/10$).

On capture précisément le point de bascule où le surapprentissage s'installe.

Plan

1. Classification d'Images (CNN CIFAR-10)

2. Séries Temporelles (LSTM)

3. Génération Textuelle (NanoGPT)

4. Modèles de Diffusion (DDPM)

5. Synthèse Croisée Globale

Anatomie de NanoGPT : La Factorisation Autorégressive

Principe du Transformer Causal :

$$P(X) = \prod_{t=1}^{N} P(x_t \mid x_{<t})$$

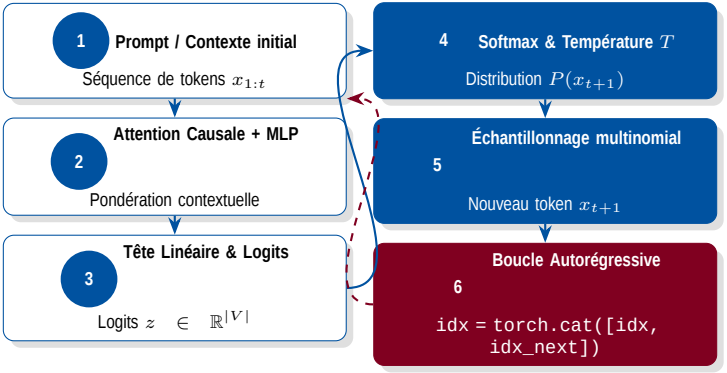
- **Entrée :** Contexte passé $x_{1:t}$.
- **Attention causale :** Masque triangulaire strict empêchant la vision future.
- **Logits & Softmax :** $P(x_{t+1} = w) = \frac{\exp(z_w/T)}{\sum_j \exp(z_j/T)}$.
- **Génération récursive :** Concaténation séquentielle de x_{t+1}.

Code source clé : `model.py` (L.283)

```
for _ in range(max_new_tokens):
  logits, _ = self(idx_cond)
  logits = logits[:, -1, :] / temperature
  probs = F.softmax(logits, dim=-1)
  idx_next = torch.multinomial(probs, 1)
  idx = torch.cat((idx, idx_next), dim=1)
```

Dépôt officiel : https://github.com/karpathy/nanoGPT

Pipeline de Décision Autorégressif (NanoGPT)



Faille structurelle : Dès qu'un token mémorisé domine ($z_w \gg z_j$), la boucle s'auto-renforce de manière déterministe.

Théorie de la Mémorisation : Perte & Longue Traîne

Cross-Entropy Loss (`train.py`) :

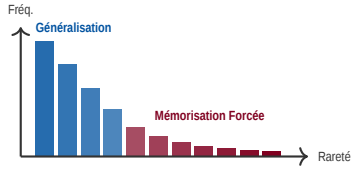
$$\mathcal{L}_{CE} = -\frac{1}{T}\sum_{t=1}^{T} \log P_\theta(x_t \mid x_{<t})$$

- $\mathcal{L}_{CE} \to 0 \implies P(x_{\text{cible}}) \to 1 \implies z_{\text{cible}} \gg z_w$.
- Sur 100–200 époques, la séquence est gravée **verbatim**.

Théorème de Feldman (STOC 2020)

Sur les distributions Zipfiennes, la mémorisation d'exemples rares est **mathématiquement requise** pour minimiser la perte.

Distribution de Zipf & Longue Traîne :



Réf : Vitaly Feldman, *Does Learning Require Memorization ?*, STOC 2020.

Attaques Déduites : Prefix-Prompting vs Extraction Aveugle

Attaque 1 : Extraction par Préfixe

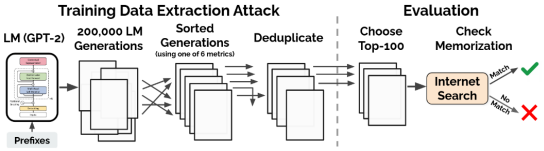
- **Hypothèse :** L'attaquant fournit le début d'un secret (*ex : «L'employé n°441 est»*).
- **Comportement :** L'attention causale focalise 100% de la masse sur le suffixe exact.
- **Résultat :** Restitution **verbatim** déterministe, même avec température $T = 1.0$.

Attaque 2 : Extraction Aveugle (Carlini 2021)

- **Hypothèse :** Aucun préfixe connu.
- **Protocole en boîte noire :**

1. Échantillonnage massif ($M = 200\,000$ textes).
2. **Problème :** Distinguer une mémorisation d'une hallucination fluide.
3. Filtrage par **Perplexité Relative**.

Workflow Officiel d'Extraction Aveugle (Carlini et al., USENIX 2021)

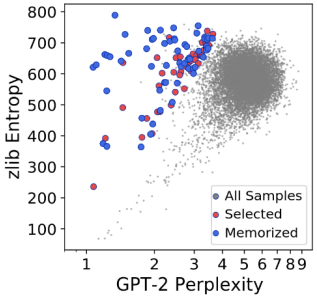


Deux étapes méthodologiques :

- **Phase 1 (Attaque) :** Génération de 200 000 échantillons avec GPT-2 XL, tri selon 6 métriques de score et déduplication.
- **Phase 2 (Évaluation) :** Inspection du Top 100, validation par recherche web et vérification OpenAI sur WebText.

Dépôt officiel : https://github.com/ftramer/LM_Memorization

Pourquoi la Perplexité Seule Échoue : Le Filtrage zlib



Ratio Perplexité / Compression zlib :

$$\text{Ratio} = \frac{\text{PPL}_{\text{Target}}(x)}{\text{Compression}_{\text{zlib}}(x)}$$

- **PPL brute favorise les répétitions triviales** («1 1 1 1»).
- **Points rouges (Top-100) :** Échantillons filtrés par le ratio.
- **Points bleus (59 confirmés) :** Extraits verbatim authentiques de WebText.
- **Signature :** Basse PPL cible mais haute complexité zlib.

Carlini et al., USENIX Security 2021.

Inférence d'Appartenance Textuelle (MIA)

Test par Seuil de Perte (Loss Thresholding)

$$\mathcal{M}(x) = \begin{cases} 1 \text{ (Membre)} & \text{si } \mathcal{L}_{CE}(x;\theta) \leq \tau \\ 0 \text{ (Non-membre)} & \text{sinon} \end{cases}$$

- Modèle sur-ajusté $\implies \mathcal{L}(x_{\text{train}}) \ll \mathcal{L}(x_{\text{test}})$.
- Seuil τ calibré sur validation disjointe.

Ratio de Référence (Carlini et al., 2021)

$$\text{Ratio}_{\text{MIA}}(x) = \frac{\mathcal{L}(x;\theta_{\text{cible}})}{\mathcal{L}(x;\theta_{\text{ref}})}$$

Élimine le biais de difficulté intrinsèque du texte.

Plan

1. Classification d'Images (CNN CIFAR-10)

2. Séries Temporelles (LSTM)

3. Génération Textuelle (NanoGPT)

4. Modèles de Diffusion (DDPM)

5. Synthèse Croisée Globale

Le Paradigme de Diffusion : Bruitage & Débruitage

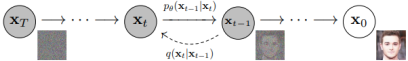


Figure 2: The directed graphical model considered in this work.

Source illustration : `lucidrains/denoising-diffusion-pytorch` · Ho et al., NeurIPS 2020

1. Processus Direct (Forward q)

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

Dégradation analytique sans apprentissage jusqu'à l'entropie maximale $x_T \sim \mathcal{N}(0, I)$.

2. Processus Inverse (Reverse p_θ)

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\, \epsilon_\theta(x_t, t) \right)$$

Débruitage itératif guidé par le réseau U-Net ϵ_θ pour inverser chaque étape.

Fondement Mathématique : Denoising Score Matching

Fonction d'Objectif Simplifiée (p_losses)

$$\mathcal{L}_{\text{simple}}(\theta) = \mathbb{E}_{t,x_0,\epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\right]$$

Le U-Net apprend à estimer exactement le bruit ϵ injecté à chaque échelle de temps t.

Lien avec la théorie de Song et al. (ICLR 2021) :

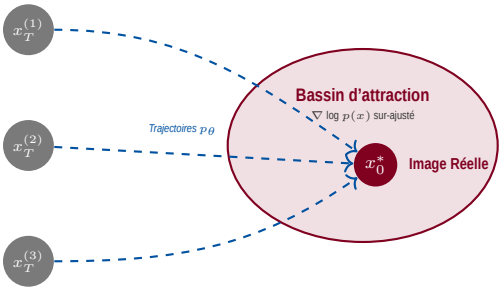
$$\nabla_{x_t} \log p_t(x_t) = -\frac{\epsilon_\theta(x_t, t)}{\sqrt{1-\bar{\alpha}_t}}$$

Interprétation physique

- Le débruitage est une intégration de trajectoire le long d'un champ de gradient.
- Le réseau « pousse » continuellement l'état x_t vers les zones de haute probabilité.

Réf : Song et al., ICLR 2021.

La Mécanique de Mémorisation : Les Bassins d'Attraction



Origine du phénomène (Carlini 2023) :

- **Duplication & Surentraînement :** Des images répétées creusent un **puits de potentiel profond**.
- **Effondrement des trajectoires :** Des bruits aléatoires distincts sont aspirés vers la même image x_0^*.
- **Conséquence :** Collision de bruits $\Longrightarrow$ Restitution verbatim de photos privées.

Déduction des Attaques : Détection de Cliques Multi-Graines

Extraction Aveugle (Carlini 2023)

- **Intuition :** En dimension 12 288, collision aléatoire quasi-impossible ($< 10^{-100}$).
- **Protocole :**

1. Tirer M bruits gaussiens $x_T^{(i)}$.
2. Calculer $d(\hat{x}_i, \hat{x}_j)$ via MSE / SSIM.
3. Isoler les **cliques** (paires avec $d < \delta$).

- Tout groupe forme une extraction vérifiée !

Amplification par CFG

$$\hat{\epsilon} = \epsilon_\theta(x_t, \emptyset) + s \cdot (\epsilon_\theta(x_t, c) - \epsilon_\theta(x_t, \emptyset))$$

- Le guidage sans classifieur ($s > 1$) accentue la force des attracteurs mémorisés.
- Élargit artificiellement la taille des bassins.

Dépôt officiel : https://github.com/ryanwebster90/onestep-extraction

Plan

1. Classification d'Images (CNN CIFAR-10)

2. Séries Temporelles (LSTM)

3. Génération Textuelle (NanoGPT)

4. Modèles de Diffusion (DDPM)

5. Synthèse Croisée Globale

Matrice Modèles $\leftrightarrow$ Attaques

Modèle	Type de Sortie	Signal Exploité	Attaque Déduite
CNN (CIFAR-10) Vision discriminative	Probabilités discrètes $P(y \mid x) = \text{Softmax}(z)$	Écart de confiance train/test $\mathcal{L}_{\text{CE}} \approx 0$ sur les membres	**Membership Inference (MIA)** Seuil de perte $\mathcal{L}_{\text{CE}} \leq \tau$ Shadow Models (Shokri 2017)
LSTM (TSGM) Séries temporelles	Valeur continue Prédiction $\hat{x}_{t+1} \in \mathbb{R}^d$	Résidu $\mathcal{L}_{\text{MSE}}$ anormalement bas Rang parmi les variantes	**MIA & Canaris** (Carlini 2019) Métrique d'Exposure Suivi temporel par checkpoint

Synthèse Périmètre Prédictif & Séquentiel

Dans les deux cas, le signal est un **résidu de confiance** issu du surapprentissage. L'attaquant en déduit une information d'appartenance (IN/OUT, rang), sans jamais recevoir la donnée brute elle-même.

Matrice Croisée : Modèles $\leftrightarrow$ Logique $\leftrightarrow$ Attaques

Architecture	Dynamique Générative	Cause de Mémorisation	Attaque Déduite & Métrique
NanoGPT Modèle de langage	Autorégressif causal $x_{t+1} \sim \text{Softmax}(z/T)$ Décision séquentielle	$\mathcal{L}_{\text{CE}} \to 0$ sur la longue traîne Sur-ajustement des logits Théorème de Feldman (2020)	**Prefix-Prompting** **Extraction Aveugle** Ratio $\text{PPL}_{\text{cible}}/\text{zlib}$ (Carlini 2021) Restitution *verbatim*
DDPM Modèle de diffusion	Processus continu inverse Débruitage itératif p_θ Intégration de gradient spatial	Score Matching $\mathcal{L} \to 0$ Duplication d'images Bassins d'attraction géants	**Détection de Cliques** Collision multi-graines Métrique : $d_2 < \delta$ ou SSIM MIA par résidu $\mathcal{E}_t \leq \tau_t$

Constat Transversal Périmètre Génératif

Bien que l'espace des données soit opposé (discret vs continu), le surapprentissage produit la même pathologie : **l'effondrement de la distribution vers des modes mémorisés déterministes**.

Prédictif vs Génératif : Inférence vs Extraction Verbatim

Distinction Fondamentale : Modèles Prédictifs vs Modèles Génératifs

Modèles discriminatifs / séquentiels (CNN, LSTM) : Le réseau ne renvoie jamais la donnée d'entraînement elle-même $\Longrightarrow$ attaques d'**inférence indirecte** (MIA, exposure).
Modèles génératifs (NanoGPT, DDPM) : La sortie peut coïncider exactement avec la donnée d'entraînement $\Longrightarrow$ attaques d'**extraction directe** (*verbatim*).

Périmètre Prédictif (Orange) : Inférence

- **Type :** Inférence binaire (IN/OUT) ou score d'exposure.
- **Signal :** Écart de perte ($\mathcal{L}_{\text{CE}}$, MSE) entre train et test.
- **Impact :** Fuite de présence dans la base d'entraînement.

Périmètre Génératif (Bleu) : Extraction Verbatim

- **Type :** Extraction directe sans invite ou guidée par préfixe.
- **Signal :** Effondrement de distribution vers des attracteurs.
- **Impact :** Restitution directe de secrets (PII, images réelles).