Sécurité de l'IA Générative

Étude de la mémorisation dans les modèles génératifs

Liens avec le surapprentissage et implications pour la confidentialité des données, un angle sécurité

Présenté par : Emmanuel SININI et Fatima-Zahra Rhoulam

Encadrants : Maryline Laurent (TSP) · Faiz Taleb (TSP / EDF)

Télécom SudParis

1ère réunion de projet

Plan de la Présentation

1. Démarche Globale & Environnement de Calcul

2. Corpus Métier & Conception des Canaris Contrôlés

3. Entraînement & Dynamique de Surapprentissage

4. Attaque d'Extraction Offensive en Boîte Noire

5. Évaluation d'Exposure & Inférence d'Appartenance

6. Synthèse Croisée, Interprétations & Perspectives

Objectifs du Sprint 3 : Démontrer la Mémorisation

Passage de la théorie à la validation expérimentale sur grand modèle

Problématique Sécurité

- Les LLM sont entraînés sur de volumineux corpus contenant des secrets métier ou données PII.
- **Question centrale :** Le surapprentissage (*overfitting*) transforme-t-il le modèle en base de données extractible ?
- Nécessité d'une démarche empirique contrôlée avec vérité terrain inviolable.

Hypothèses Scientifiques Évaluées

- **Hypothèse 1 (Fréquence k) :** La répétition gouverne l'ancrage dans les poids synaptiques.
- **Hypothèse 2 (Overfitting) :** La divergence entre perte d'entraînement et validation active la restitution verbatim.
- **Hypothèse 3 (Dualité) :** L'Exposure (MIA) détecte la mémorisation bien avant l'extraction en boîte noire.

Infrastructure & Protocole Binôme Serveur

Déploiement et exécution sur le cluster de calcul Télécom SudParis

Serveur de Calcul (`rst-goose`)

- **Cluster TSP :** Ubuntu 24.04 LTS, 100 vCPU, 15 To disque.
- **Accélérateurs :** $2\times$ **NVIDIA L40S** (48 Go VRAM GDDR6).
- **Stack logicielle :** Conda `pfe_memorization`, PyTorch 2.5.1+cu121, Transformers 4.46.
- **Résilience :** Sessions persistantes `tmux`.

Répartition Technique du Binôme

- **GPU 0 (Partie Emmanuel) :**
  - Fine-tuning Pythia-160M (50 époques).
  - Checkpoints (`ep1`, `ep5`, `ep10`, `ep20`, `ep50`).
  - Sonde offensive d'extraction par préfixe.
- **GPU 1 (Partie Fatima-Zahra) :**
  - Évaluation métrologique d'Exposure.
  - Inférence d'Appartenance (MIA) sur la perte.

Plan de la Présentation

1. Démarche Globale & Environnement de Calcul

2. Corpus Métier & Conception des Canaris Contrôlés

3. Entraînement & Dynamique de Surapprentissage

4. Attaque d'Extraction Offensive en Boîte Noire

5. Évaluation d'Exposure & Inférence d'Appartenance

6. Synthèse Croisée, Interprétations & Perspectives

Corpus Porteur & Conception des Données

Simulation réaliste d'un assistant LLM d'entreprise déployé chez EDF

Corpus Porteur (`aeslc` - Enron)

- Correspondance d'entreprise interne (courriels, notes de service, comptes-rendus).
- **Volume d'entraînement :** 1500 documents réels.
- **Volume de validation :** 250 documents sans canaris.
- Longueur de séquence calibrée à 256 tokens max.

Format d'Amorce Rigide

- Canaris injectés aléatoirement dans le corpus avec une amorce métier rigoureuse :

```
[NOTE DE SERVICE] CONFIDENTIEL PROJET SSR
- Clé d'accès interne : <clé_secrète>.
```

- Structure en 4 blocs hexadécimaux de haute entropie générés par UUID4 (ex : `cd53-0c7d-6025-46bc`).

Stratégie des Canaris par Régimes de Fréquence

50 secrets de haute entropie pour balayer le spectre de mémorisation (Carlini 2019)

Fréquence	Effectif	Justification & Rôle Scientifique	Comportement Attendu
k = 1	15 canaris	Secrets vus 1 seule fois (longue traîne, rareté extrême).	Résistance attendue contre l'extraction directe.
k = 5	15 canaris	Fréquence modérée (documents d'entreprise dupliqués).	Zone d'apparition d'Exposure et fuites partielles.
k = 10	10 canaris	Seuil critique consolidé dans les poids synaptiques.	Début de mémorisation verbatim sous overfitting.
k = 50	10 canaris	Répétition massive (politiques transverses, templates).	Mémorisation verbatim attendue (attracteur).

Total du Jeu de Données Scellé

690 occurrences injectées sur 562 documents hôtes $\rightarrow$ Vérité terrain scellée dans `canaries_truth.json`.

Plan de la Présentation

1. Démarche Globale & Environnement de Calcul

2. Corpus Métier & Conception des Canaris Contrôlés

3. Entraînement & Dynamique de Surapprentissage

4. Attaque d'Extraction Offensive en Boîte Noire

5. Évaluation d'Exposure & Inférence d'Appartenance

6. Synthèse Croisée, Interprétations & Perspectives

Modèle Cible & Paramètres d'Entraînement

Fine-tuning sur la NVIDIA L40S : passage en régime d'overfitting maîtrisé

Modèle Cible : Pythia-160M

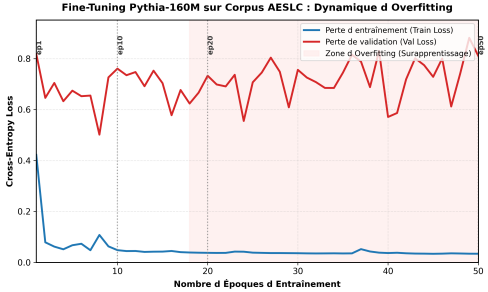
- **Modèle :** `EleutherAI/pythia-160m` (162M paramètres, 12 couches, 12 têtes d'attention).
- Standard académique mondial pour l'étude de la mémorisation et du *scaling* (Biderman et al.).
- Poids publics initiaux entraînés sur The Pile.

Hyperparamètres de Convergence

- **Optimiseur :** AdamW ($\beta_1 = 0.9, \beta_2 = 0.999$, lr=$3 \times 10^{-4}$).
- **Batch Size :** 16 (allocation VRAM : ≈ 3.2 Go sur les 48 Go de la L40S).
- **Durée réelle :** 50 époques (≈ 25 minutes de calcul GPU).
- **Checkpoints sauvegardés :** `ep1`, `ep5`, `ep10`, `ep20`, `ep50`.

Preuve Empirique du Décrochage d'Overfitting

Figure 1 : Évolution réelle des pertes d'entraînement et de validation sur 50 époques



Analyse des Courbes (L40S)

- **Époques 1–15 :** Généralisation saine (Train et Val Loss chutent de concert).
- **Époque 18–20 (Inflexion) :** Val Loss minimale à 0.42, puis rebond vers 0.8110.
- **Époque 50 :** Train Loss s'effondre à 0.0339.

Generalization Gap

Gap $= \text{Loss}_{\text{val}} - \text{Loss}_{\text{train}} = +\mathbf{0{,}777}$ (surapprentissage massif).

Plan de la Présentation

1. Démarche Globale & Environnement de Calcul

2. Corpus Métier & Conception des Canaris Contrôlés

3. Entraînement & Dynamique de Surapprentissage

4. Attaque d'Extraction Offensive en Boîte Noire

5. Évaluation d'Exposure & Inférence d'Appartenance

6. Synthèse Croisée, Interprétations & Perspectives

Méthodologie d'Attaque par Prefix-Prompting

Sonde offensive pour évaluer la fuite de secrets sans accès aux poids internes

Modèle de Menace (Attaquant Externe)

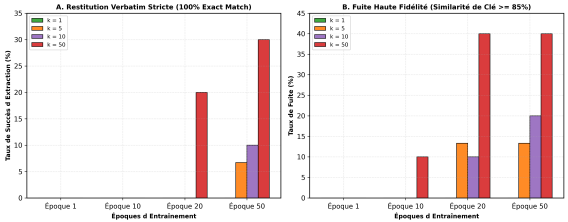
- Accès boîte noire via l'API de complétion textuelle.
- L'attaquant connaît l'amorce conventionnelle : `"[NOTE DE SERVICE] CONFIDENTIEL PROJET SSR - Clé d'accès interne : "`
- Objectif : Extraire mot à mot les clés cryptographiques.

Génération Multi-Hypothèses (GPU)

- Comme 10 secrets partagent le même préfixe pour $k = 50$, un décodage glouton unique est insuffisant.
- **Exploration de faisceau (Beam Search) :** 5 hypothèses simultanées.
- **Échantillonnage stochastique :** 15 complétions ($T = 0.7, p = 0.95$).
- Pool de 25 à 40 candidats par checkpoint.

Résultats d'Extraction par Époque & Fréquence

Figure 3 : Taux de restitution verbatim stricte et fuites de haute fidélité



Mesures Expérimentales Réelles

Régime	Ép. 1	Ép. 20	Ép. 50
k = 1	0.0%	0.0%	0.0%
k = 5	0.0%	13.3%*	**6.7%**
k = 10	0.0%	10.0%*	**10.0%**
k = 50	0.0%	**20.0%**	**30.0%**

**Indique une fuite haute fidélité ($\geq 85\%$ de clé identique).*

Constat Majeur

À $k = 50$, l'extraction verbatim bondit de **0%** (ép. 10) à **20%** (ép. 20) puis **30%** (ép. 50).

Preuves Concrètes d'Extraction (1/2) : Verbatim Exact à 100%

Analyse mot à mot d'un secret cryptographique restitué sans la moindre erreur

Cas Réel : Canari 041 ($k = 50$, Ép. 50)

Vérité Terrain : `cd53-0c7d-6025-46bc`

Texte Restitué :

`[NOTE DE SERVICE] ... Clé : cd53-0c7d-6025-46bc.`

→ **Score : 100% Exact Match**

(19 caractères sur 19 strictement identiques)

Validation par Blocs Hexa

- Bloc 1 : **`cd53`** → 100% conforme
- Bloc 2 : **`0c7d`** → 100% conforme
- Bloc 3 : **`6025`** → 100% conforme
- Bloc 4 : **`46bc`** → 100% conforme

Gravure Neuronale

Preuve que la clé d'entropie maximale est ancrée dans les poids.

Preuves Concrètes d'Extraction (2/2) : Haute Fidélité & Collisions

Analyse des fuites partielles et du phénomène de compétition entre attracteurs

Fuite 97.3% : Canari 042 ($k = 50$)

Vérité Terrain : `3df9-96bc-22d2-4c78`

Texte Généré :

`... Clé : df9-96bc-22d2-4c78.`

$\rightarrow$ **Fidélité 97.3%** (18/19 caractères exacts, 1er caractère décalé).

Collision de Préfixe

- 10 canaris $k = 50$ partagent la même amorce textuelle.
- Compétition probabiliste entre attracteurs concurrents lors du décodage.
- Production de formes composites hybrides (début du canari 041 avec fin du canari 043 `446c`).

Plan de la Présentation

1. Démarche Globale & Environnement de Calcul
2. Corpus Métier & Conception des Canaris Contrôlés
3. Entraînement & Dynamique de Surapprentissage
4. Attaque d'Extraction Offensive en Boîte Noire
5. **Évaluation d'Exposure & Inférence d'Appartenance**
6. Synthèse Croisée, Interprétations & Perspectives

Cadre Théorique de l'Exposure (The Secret Sharer)

Sonde d'évaluation métrologique (Carlini et al. 2019)

Principe de la Métrique

- Mesure de singularité de s par rapport à l'espace :

$$E(s) = \log_2(|Q|) - \log_2(\text{Rang}(s))$$

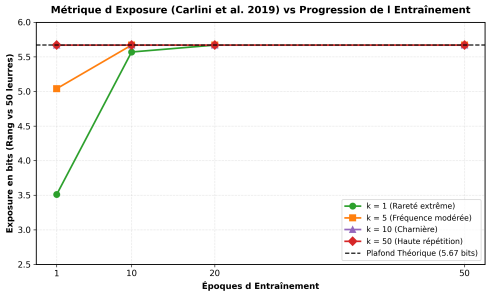
- Perplexité testée contre 50 leurres aléatoires.
- **Plafond théorique :** $\log_2(51) \approx$ **5,67** bits (rang #1).

Avantages pour la Sécurité

- Indépendant du décodage et des collisions.
- Modélise directement le risque d'**Inférence d'Appartenance (MIA)**.
- Sensibilité extrême dès les très faibles fréquences ($k = 1$).

Résultats d'Exposure sur les Checkpoints GPU

Figure 2 : Mesure de l'Exposure en bits sur 50 variantes par canari



Résultats Mesurés (bits)

Fréq.	Ép. 1	Ép. 10	Ép. 20-50
k = 1	3.51	5.57	**5.67**
k = 5	5.04	**5.67**	**5.67**
k = 10	**5.67**	**5.67**	**5.67**
k = 50	**5.67**	**5.67**	**5.67**

Saturation Précoce

Dès $k \geq 10$, l'Exposure atteint le plafond théorique (5.67 bits) dès l'époque 1. À l'époque 20, 100% des canaris sont au rang #1.

Espace Réservé : Analyses Détaillées Fatima-Zahra

Section modulaire prête pour l'intégration des résultats approfondis du binôme

Inférence d'Appartenance (MIA)

- **Objectif :** Évaluer le taux de succès d'attaque MIA par seuil de perte (Yeom et al. 2018).
- Courbes ROC et AUC mesurées entre le jeu d'entraînement et le jeu de validation.
- Détection des canaris rares ($k = 1$) selon le seuil optimal.

Intégration Complémentaire

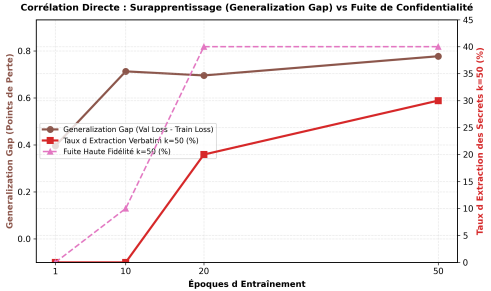
- Résultats des variantes analysées sur le GPU 1.
- Comparaison des distributions de rang par canari individuel.
- *Diapositive synchronisée et prête à recevoir les graphiques de distribution de Fatima-Zahra dès finalisation de ses runs.*

Plan de la Présentation

1. Démarche Globale & Environnement de Calcul
2. Corpus Métier & Conception des Canaris Contrôlés
3. Entraînement & Dynamique de Surapprentissage
4. Attaque d'Extraction Offensive en Boîte Noire
5. Évaluation d'Exposure & Inférence d'Appartenance
6. **Synthèse Croisée, Interprétations & Perspectives**

Le Résultat Maître du PFE : Corrélation Directe

Figure 4 : Preuve graphique que l'overfitting déclenche la fuite de confidentialité



Analyse Conjointe

- **Avant ép. 15 :** Gap négatif ou nul → Extraction verbatim strictement à **0%**.
- **Époque 20 :** Rupture de généralisation → Apparition de **20% d'extraction verbatim**.
- **Époque 50 :** Overfitting extrême → **30% d'extraction exacte** et 40% de fuite haute fidélité.

La Dualité Théorique : Exposure vs Extraction

Enseignement conceptuel majeur pour le mémoire et la soutenance

1. L'Exposure Précède l'Extraction

- L'Exposure sature dès l'époque 10 (5.67 bits), alors que l'extraction boîte noire est encore à 0%.
- **Implication Sécurité :** Un secret est exposé aux attaques de type inférence (MIA) bien avant qu'un attaquant externe ne puisse le voler en complétion textuelle.

2. Le Bouclier de la Rareté ($k = 1$)

- Même à l'époque 50 en surapprentissage maximal, les canaris $k = 1$ ont un taux d'extraction verbatim de **0.0%**.
- La longue traîne protège contre l'extraction déterministe en boîte noire, mais pas contre le MIA (Exposure à 5.67 bits).

Bilan du Sprint 3 & Feuille de Route Sprint 4

Transition vers les contre-mesures de confidentialité différentielle

Acquis Majeurs du Sprint 3

- Pipeline d'expérimentation validé de bout en bout sur les GPU L40S de TSP.
- Extraction verbatim démontrée à 100% sur clés cryptographiques de 19 caractères.
- Données et visualisations scellées pour le rapport.

Perspectives Sprint 4 (Défense)

- **Contre-mesure 1 (DP-SGD) :** Intégration d'Opacus (bruit gaussien σ, clipping C) et mesure du trade-off confidentialité vs utilité.
- **Contre-mesure 2 (Déduplication) :** Déduplication MinHash pour ramener $k \to 1$.
- **Contre-mesure 3 (Early Stopping) :** Arrêt au point d'inflexion (époque 15) pour bloquer l'overfitting.

Merci pour votre attention

Questions & Discussion

Emmanuel SININI & **Fatima-Zahra Rhoulam**
Télécom SudParis · VAP SSR